课程项目 · 三人三 AI 协作

北京空气质量

短期预测 · 项目指导书

机器学习训练 · 公平评价 · 图形交互

> 项目定位： 使用北京多站点历史监测记录，训练机器学习模型，在历史回放中预测提前 1、3、6 小时对应的 PM2.5 小时浓度，并通过点击、筛选、时间滑块和图表比较结果。近期正式数据拟采用 2024—2025 年；已有近年样本与 UCI 完整历史数据的核验依据，完整近期数据采集与正式训练属于后续实施。本书交付的是项目实施规范，不表示软件、正式数据管道或模型已经完成。

统一定义提前 1、3、6 小时的预测目标，覆盖近期数据方案、严格历史特征、两类基线、RF/GBT、独立验收及三人三 AI 协作。

V1.0 / 2026 年 10 月 16 日

适用：课程项目规划、分工实施、实验复现与答辩验收。

阅读导航

三人先共同阅读第 1—4、10、13、14 章；AI 按第 16 章提示词接手。附录提供配置、检查单和现有核验依据。

01 项目摘要与执行入口 3

02 研究问题、功能范围与可行性 4

03 数据来源、现有证据与获取方案 6

04 验收目标与结论边界 8

05 总体架构与技术环境 9

06 统一时间、目标和数据契约 10

07 数据清洗、覆盖与质量验收 13

08 时间切分、特征与信息边界 14

09 基线、机器学习与实验预算 16

10 评价协议：怎样证明模型有用 18

11 图形交互与页面规格 21

12 服务接口、结果库与信息门控 22

13 三人三 AI 分工与交接 24

14 排程、验收门与风险处置 25

15 成果包、性能证据与答辩 27

16 三位 AI 的启动提示词 28

附录 A 配置、表格和检查模板 30

附录 B 现有证据与来源 31

01 项目摘要与执行入口

本书依据当前讨论独立成稿，替代先前共享单车方案的选题和实施约定。团队已经明确：以机器学习训练和短期预测为核心，以图形交互展示信息；首版采用规则基线、随机森林和梯度提升树。大语言模型不进入产品功能，深度学习作为可选扩展，由核心版本验收后的资源与实验需要决定。

正文 Markdown 是内容唯一主版本，Word 用于阅读与批注，PDF 用于固定版面分享。三位成员负责判断与验收，各自的 AI 辅助研究、实现和检查。第 16 章可直接复制对应角色的启动提示词；其余章节给出三方共用的字段、时间、评价和交接定义。

1.1 题目与一句话目标

建议正式题目为：**基于 Hadoop 与 Spark 的北京多站点 PM2.5 短期预测与可视化分析系统**。对外展示可简称“北京空气质量短期预测系统”。模型的核心目标是 PM2.5 浓度，不把完整天气预报、AQI 指数换算或健康建议混成同一个任务。

一句话目标：从公开历史记录中构建可信的站点时序数据，用过去已知信息预测未来小时浓度，检验机器学习能否超过简单历史规则，并让用户通过图表交互理解结果、误差和局限。

1.2 首版已经选定的设计

决策	本指导书的统一选择
地区与目标	北京多个监测站，预测 PM2.5 小时均值，单位 $\mu g/m^3$
近期正式范围	拟用 2024—2025 年；完整采集和质量验收后冻结数据版本
预测跨度	提前 1、3、6 小时分别建模；6 小时为主比较，1、3 小时为辅助
输入信息	历史污染浓度、已知日历、站点；气象特征经配套数据验证后扩展
算法	持久性基线、上一日同期基线、随机森林 RF、梯度提升树 GBT
运行方式	固定训练模型，按整点滚动历史回放；首版没有实时监测接入承诺
用户交互	点击站点、选日期、拖时间、切预测跨度和模型、查看误差案例
团队分工	A 数据与环境；B 模型与实验；C 应用与独立验收；每人配一位 AI

1.3 完成状态与下一步的界线

已存在的证据： 2026 年 10 月 15 日已实际取得并解析四个近年北京日样本，分别为 2024-01-01、2025-01-01、2026-01-01、2026-10-13；另已完整取得 UCI 北京多站点历史归档并核验 12 个 CSV，共 420,768 行。随附核验记录保存日期、字段、数量与哈希。

尚待实施： 2024—2025 年全量下载与连续性检查、站点映射和用途确认、Spark 项目环境验证、正式特征和模型、图形界面、最终测试。文档里的模型配置和命令是规格，不是已有可执行工具或已取得成绩。

第一次实施先完成 A01 的近期数据取得与验收，同时 B01 和 C01 可使用明确标记的人工小样例开发契约和评价。先联通一个真实站点、一个发布时点、一个 6 小时跨度，再放大到全范围。

1.4 阅读与首次会议

三人共同先读第 1—4、10、13、14 章，确认范围、数据状态、评价、责任和验收。A 重点读第 3、5—7 章，B 重点读第 6、8—10 章，C 重点读第 6、10—12 章。AI 都应先读第 1、3、6 章，再按自己的任务定位其他章节。

首次会议填写成员姓名、主责、每周投入、课程最终期限、提交形式，以及是否强制 MapReduce、Spark on YARN 或真实多机集群。按此前沟通，本周日 2026 年 10 月 18 日是选题确定节点；最终验收日期尚未在本会话中明确。本书的相对排程不是老师发布的正式期限。

02 研究问题、功能范围与可行性

2.1 四个研究问题

RQ1 数据与时空变化： 不同站点、季节、时段的 PM2.5 水平有何差别？用真实数据的分布图、站点对比和时间曲线回答，并同时展示缺失覆盖。

RQ2 预测是否有效： 机器学习在未参加训练的后续时段，能否比“未来保持最近浓度”和“沿用昨天同小时”更准确？用固定测试集合的 MAE、RMSE 与配对误差比较回答。

RQ3 是否能捕捉高浓度时段： 模型是否容易漏掉相对高浓度小时？用训练期定义的峰值阈值、Precision、Recall、F1 和失败案例回答。

RQ4 工程是否可信： 数据处理能否对账、实验能否复现、页面是否准确表达结果？用独立核算、版本清单、日志和界面验收回答。

2.2 方法适合什么任务

本项目把历史记录转成监督学习样本：“过去观测与日历”是输入，“后续真实浓度”是标签。模型学习历史统计关系；这是可验证的短期时序回归任务。方法的适用性不等于必然超过基线，是否改善必须由真实未来测试确定。

近年日文件含小时级污染记录，足以设计只用污染历史的首版。风速、气温等可能提供额外信息，但需独立取得、匹配并做消融。首版不以尚未落实的气象字段作为开工前提，也不以未来实测天气代替当时可获得的信息。

2.3 首版必做与扩展

必做首版包括：来源与质量登记、近期数据标准化、站点小时表、时间切分、两个规则基线、RF 与 GBT、三个预测跨度、逐行预测与独立评价、站点趋势与历史回放页面，以及复现和答辩材料。

扩展按顺序选择：配套气象特征、更多真实年份或京津冀站点、轻量 LSTM、经验证的实时数据源。新增内容需单独说明数据、预算与评价，核心版本先验收。大模型问答、账户与支付、完整天气预报、污染来源因果识别均不作为本项目任务。

2.4 三项可行性判断

数据可获取性较高。 已有近期样本实测和明确历史下载入口；完整 2024—2025 年范围仍需采集验收。与之前没有合格美团数据的情形不同，此处有真实可读的近期监测样本作为直接依据，但样本不能冒充完整年度。

方法与评价路径明确。 两个基线、两种成熟树模型和未来标签足以形成完整课程实验。研究价值来自可信的数据处理、公平比较和结果解释，不要求发明全新算法。

三人能够分层交付。 数据、模型、应用分别主责，依赖用版本化文件约定。实际耗时、内存和模型增益尚未测出；三人按可投入时间调整扩展，避免把估算写成保证。

03 数据来源、现有证据与获取方案

3.1 近期主数据来源

近期主数据候选为王晓磊维护的空气质量历史归档。发布者提供单日 CSV 和年度包，并说明北京记录来自环境监测网站、部分日期可能因故缺失。它是第三方历史归档，不是本次从政府接口直接取得的完整数据。[S1]

首版读取 `beijing_all_YYYYMMDD.csv` 中的 `PM2.5` 小时值。该文件还包含 PM10、AQI 及滚动统计类型；首版基本特征仅取有定义的小时 PM2.5，不将 `_24h` 等行重复计作独立小时观测。取得配套字段后再分版本扩展输入。

3.2 四个已核验日样本

日期	当前实际检查结果
2024-01-01	120 行、35 个站点列；PM2.5 有 24 个小时时点，786 个非空站点小时值
2025-01-01	120 行、35 个站点列；PM2.5 有 24 个小时时点，838 个非空站点小时值
2026-01-01	120 行、35 个站点列；PM2.5 有 24 个小时时点，837 个非空站点小时值
2026-10-13	120 行、35 个站点列；PM2.5 有 24 个小时时点，835 个非空站点小时值

每站每日理论有 24 个 PM2.5 值，35 站上限为 840；上表的差额体现空值，不能按“有 24 行”推断所有站点都完整。120 行是多种类型的宽表行数，不等于 120 次独立 PM2.5 观测，也不等于 35 个站点已经跨年身份一致。

3.3 已落实的历史演练与备选数据

UCI 的 Beijing Multi-Site Air Quality 是独立历史数据集，覆盖 2013-03-01 至 2017-02-28，含污染与配套气象，官方页面列 CC BY 4.0。此前已实际下载、校验外层和嵌套归档，12 站 CSV 各 35,064 行，总计 420,768 行，PM2.5 缺失 8,739 条。[S2]

它可用于真实小链路演练或明确标为历史的独立实验。近期与历史数据分别使用数据集 ID、站点映射和实验配置，不能直接拼成一条跨十年的序列。若近年正式范围无法满足课程要求，使用 UCI 作为正式替代须团队重新确认范围，不能将它描述为最新数据。

此前在 UCI 数据上做过简单基线可行性计算；该结果不是近期模型成绩。本书不复制那组数值充当正式测试。

3.4 首次实施的数据获取顺序

1. 保存来源说明、取得日期和适用用途；确认团队课堂使用与成果分享方式。近期归档没有像 UCI 一样明确标出标准许可证，应保留来源署名，不自行宣称它采用 CC BY。
2. 优先查看发布者提供的年度归档；如按日取得，按 2024—2025 年日期清单逐日记录状态，控制并发和重试，遵守来源要求。
3. 下载先用临时后缀；检查响应、文件内容、表头和业务日期后登记 SHA-256，再转正式文件。HTTP 200 或 CSV 扩展名不能替代内容检查。
4. 枚举 2024 年 366 天和 2025 年 365 天；失败、缺失、重复、空文件和错误日期都进入 manifest，不用最近一天补前一天。
5. 先对一个完整月做宽转长、站点和时间检查，再扩至两年。原始文件保持只读，清洗与实验另留版本。
6. A 交付完整采集清单，B 判断能否形成拟定实验，C 独立抽查后签署数据范围冻结决定。

本次指导书制作不追加年度下载、不启动虚拟机或训练软件。以上是后续实施任务的顺序，不表示已经执行。

3.5 规模与数据范围调整

若两年均有 35 个稳定站点且每小时都完整，理论 PM2.5 站点小时量为 `731 × 24 × 35 = 614,040`。这是上限预算，不是实测有效量。实际站点数、站点更名、缺测和源文件缺失都会改变可用规模。

该规模能支撑课程中的分区处理、时序特征和算法比较；应如实称课程规模数据，不能包装成亿级数据或已验证的多机加速。后续可扩展同源更多年份或京津冀真实站点，先评估取得成本和时空一致性。

若默认期间严重不连续，在正式测试打开前由三人共同调整为同一来源的较完整区间，优先保留完整季节与独立后续测试。变更必须重写配置、解释原因并生成新版本；不能在看过模型得分后换到更容易的日期。

3.6 可使用与可发布分别确认

A 记录来源名称、入口、用途说明、署名要求、原始数据再发布边界和复核日期。课堂研究、团队内部访问、公开代码、图表展示与原始数据打包不是同一事项；分享指导书不附带近期原始年度包。需要对外公开原始资料而来源规则不明确时，先取得提供方确认。

正规 API、年度下载与公开日文件各按自身访问规则使用。文档不要求代用户注册账号、使用他人凭据、绕过限制或提交对外申请。

04 验收目标与结论边界

4.1 工程、算法与展示分别验收

工程通过要求来源可追溯、字段和小时量可对账、流水线可重复运行、错误可定位。算法通过要求时间边界正确、基线和模型在相同样本上比较、完整覆盖、指标可独立重算。展示通过要求用户能通过交互查到真实结果，预测与实测、缺失与零值清楚区分。

把“6 小时测试 MAE 相对强基线改善 5%”作为努力目标可以，但它既不是既定成果，也不是老师已发布的及格线。若模型没有胜过基线，保留完整结果和分析；系统可使用表现更好的规则方法，工程与可靠评价仍有价值。

4.2 可以支持的说法

可以报告指定来源、站点和时间范围内的 PM2.5 短期预测表现、高浓度小时识别、站点差异与处理性能。指标单位、测试时间和覆盖量应与结论一同出现。

历史记录不能单独证明某次污染由具体工厂、交通或气象因素造成。模型特征重要性只能说明模型如何利用变量，不是因果证据。预测表现也不能自动推出健康改善、减排量或管理成本收益。

4.3 历史回放与实时服务

近期归档按日发布，文件存在不意味着当年每个小时都实时可得。首版采用历史回放：假设监测小时结束后其数值可用于下一整点预测，并明确标为理想化的历史信息可得假设。

该假设可以用于公平比较预测方法，但不证明从这个按日归档入口能实际提供实时 1 小时预报。若以后要上线实时预测，必须另行接入获准的小时观测流，实测延迟、缺测与发布时间，并重新检查特征和评价。

05 总体架构与技术环境

5.1 一条数据到结果的链路

来源清单与原始日文件
→ HDFS 原始层 → 宽转长与质量处理
→ 站点小时表与覆盖表 → 严格历史特征
→ 两个基线 / RF / GBT → 固定模型滚动回放
→ 逐行预测与独立评价 → 只读查询库
→ API → 站点选择、时间滑块与图表

A、B、C 通过版本化 Parquet、JSON 和服务库交接。网页读取预先计算好的结果，用户点击不会触发 Spark 训练。训练产物和展示产物按 `dataset_id / run_id` 区分，历史运行不被覆盖。

5.2 首版技术选择

层	选择	用途与约束
存储	HDFS、Parquet	原始只读、清洗分区、产物版本化
数据与模型	PySpark SQL、Spark ML	聚合、窗口特征、RF/GBT；先单机 local[2]
服务	Python FastAPI、SQLite	结果导入后只读，服务不训练模型
前端	Vue 3、TypeScript、ECharts	曲线、热力矩阵、指标、时间滑块与筛选
地图	经坐标核验的底图与站点图层	坐标未验证时用站点列表和矩阵保持交互完整
协作	Git、schema、OpenAPI	三人独立工作目录；公共契约统一版本

若团队已有熟悉的等价前端栈，可在启动会议统一替换。三位 AI 使用同一套技术决定，不各自引入不同框架、数据库或服务体系。

5.3 既有环境与兼容性验证

现有记录中的环境为 Ubuntu 24.04 虚拟机，4 vCPU、8 GB RAM、40 GB 虚拟磁盘；Java 17、Hadoop 3.5.0。2026 年 10 月 11 日有 HDFS、YARN 与 WordCount 验证记录；该历史成功不能当成本项目 Spark 或模型已验证。

共享目录为 `/mnt/hgfs/SoftwareLabs`，Hadoop 位于 `/usr/local/hadoop-3.5.0`，运行数据位于 `/srv/softwarelabs/runtime`。保留现有课程资料与虚拟机，不重新格式化 NameNode。

项目建议候选为 Spark 4.0.1、独立 Python 3.12 环境。Spark 官方说明支持 Java 17/21、Python 3.9 以上并使用 Hadoop 客户端访问 HDFS；与本机 Hadoop 3.5.0 的实际组合需在 G1 验证并锁定版本。[S3][S4]

先使用 `local[2]` 和约 2 GB driver，分别测小表读写、Parquet、窗口计算及极小 RF/GBT。不要同时把 driver、YARN executor 和大量缓存挤入 8 GB 虚拟机。宿主与虚拟机分别检查磁盘；完整展开、HDFS、副本、缓存与多次实验的峰值开销实施后再预算。

5.4 拟建目录与命令

```
aircast/
  configs/          来源、时间和模型配置
  contracts/        schema.json 与 api.openapi.yaml
  src/aircast/
    data/           A：采集、清洗、质量、小时表
    model/          B：特征、训练、回放、评价
    serving/        C：导入、查询、HTTP API
    common/         时间和公共字段工具
  frontend/         C：交互页面
  tests/            数据、模型、契约与独立验收
  fixtures/         有标识的人工样例
  docs/             决策、交接、实验与复现说明
  artifacts/        按运行版本留存产物
```

`aircast` 是拟建课程工程包名，三组使用同一名称与入口。

拟实现入口为 `python -m aircast.data.cli`、`python -m aircast.model.cli`、`python -m aircast.serving.cli`，分别支持采集 / 质量 / 小时表、特征 / 训练 / 回放 / 评价、导入 / 服务等子命令。当前这些入口尚未实现，每个入口需有 `--help`、配置路径、输出目录、日志和明确失败退出码。

06 统一时间、目标和数据契约

6.1 三个跨度究竟预测什么

设整点 T 为预测发布时间，已完成的最近监测小时是 `[T-1 小时,T)`。只用 T 之前可知的信息，跨度 h 取 1、3、6，预测目标为：

```
target_start = T + (h - 1) 小时
target_end   = T + h 小时
target       = [target_start, target_end) 的 PM2.5 小时均值
```

因此 h=6 是最近已知小时之后第六个小时的浓度，不是未来六小时累计值或平均值；h=1、3、6 是三个单独目标，不表示已经生成未来连续六个小时的全部预测。

例：北京时间 2025-07-01 10:00 发布，最近可用值是 09:00—10:00 的小时浓度。1 小时目标为 10:00—11:00，3 小时为 12:00—13:00，6 小时为 15:00—16:00。若数据提供方对原始 hour 的起止定义不同，A 必须先确认并统一映射，随后整体版本化更新，不能一组当开始一组当结束。

6.2 原始时间与可得时间

来源 `date/hour` 暂按 Asia/Shanghai 当地小时开始解释，需写入时间政策并核对说明。标准表使用 UTC 时间主键，界面显示北京时间；保留原始日期与小时便于追溯。接口统一带 `Z` 的 ISO 8601 字符串。

区分三种时间：监测发生的小时、小时结束时间、数据实际可获得时间。首版没有真实到达日志时，使用第 4.3 节的小时结束可得假设，`availability_policy=hour_end_assumed`。以后有发布日志则用真实 `available_at`；不能用归档文件的下载时间代替历史可得时间。

6.3 数据版本与站点身份

公共版本字段为 `dataset_id`、`schema_version`、`station_version`；实验还含 `feature_version`、`protocol_id`、`run_id`。近期、UCI、人工样例分别用独立数据集 ID，不能合表后丢掉来源身份。

站点名称不是永远稳定的 ID。A 建立站点注册表，含规范 `station_id`、来源名称 / 代码、别名与有效日期、映射依据、可选经纬度与坐标系。更名、迁移或不确定匹配进入人工复核；未知站点不能靠相似字符串自动并入旧站。

经纬度和坐标系有可复核来源时才能上地图。缺位置不影响该站时间建模，界面用列表与热力矩阵；不手工猜点或默认把百度坐标当 WGS84。

6.4 站点小时表：A 向 B 的核心交付

字段	类型与含义
dataset_id / schema_version	非空字符串，来源数据版本与字段版本
station_id / station_version	非空字符串，注册站点与映射版本
hour_start_utc / hour_end_utc	UTC 时间，右边界等于左边界加一小时

字段	类型与含义
pm25_observed	可空 Float64，原始观测的小时浓度，μg/m³
observation_status	observed、missing_source、missing_value、invalid_value
local_date / local_hour	北京日期与 0—23 小时
source_ref / quality_flags	文件 / 页定位与可审计质量标记
availability_policy	hour_end_assumed 或采用真实发布日志的版本

主键为 `dataset_id + station_id + hour_start_utc`。`pm25_observed` 保留真实值；源缺失、数值空缺或非法值为 null 并带原因。零值不能自动当空值，空值也不能补零。

输入特征的插补另存特征层；评价真值始终来自原始有效观测，不能把插补标签当真实答案。PM10、其他污染物或气象新增列需同步数据版本与特征版本，不静默复用旧模型。

6.5 预测表

预测记录至少包含：数据和站点版本、`run_id`、`model_id`、`station_id`、`issue_time_utc`、`horizon_hours`、`target_start_utc`、`target_end_utc`、`prediction`、`prediction_origin`、`feature_version`、`protocol_id`。

唯一键为 `run_id + model_id + dataset_id + station_id + issue_time_utc + horizon_hours`。`prediction` 必须为有限非负浮点数；树模型输出统一截断到至少零，评价前不取整。`prediction_origin` 区分模型与后备值。

6.6 固定评价索引和真值

B 在正式模型训练前生成固定候选索引，按数据质量及统一资格规则登记 `dataset_id`、站点版本、站点、发布时间、跨度、目标起止、split、eligible、资格原因。协议冻结入选站点、索引和真值表的版本与哈希。

每个跨度有自己的固定计分集合，所有模型在该跨度使用同一集合。跨度之间可有不同边界样本量，不能把它们混成一个总体误差。C 按同一键关联原始观测真值，先检查应有、重复、额外和缺失预测，再计算指标；不通过内连接悄悄丢掉缺预测。

6.7 服务空值和错误含义

内部成功预测行必须有数值，无法预测时输出失败清单并按评价覆盖规则处理。服务响应可以有空值，但必须配 `forecast_status`：ok、outside_panel、missing_history、not_yet_issued。

`actual_value` 为可空浮点；`actual_status` 为 observed、not_yet_observed、missing_source、missing_value 或 invalid_value。界面将缺失、未发生和真实零值区别显示。

07 数据清洗、覆盖与质量验收

7.1 原始宽表转换

北京日文件的每行对应日期、小时和一种类型，各站点分别是列。读取时显式保留前三列，将站点列展开成“站点—小时—类型—数值”的长表，再筛取 `type=PM2.5` 建立模型目标。

每个文件检查业务日期与文件名一致，hour 为 0—23，类型和列名无重复。`PM2.5_24h` 是不同统计类型，不能误当作小时 PM2.5；AQI 是指数，不是 μg/m^3 浓度。单位和类型混淆直接阻断验收。

7.2 去重和异常处理

重复下载同一文件、重复日期小时类型或同站点小时多值，先判断来源版本与冲突。完全相同的重复可按固定规则去重；不一致值输出冲突清单，不能任意平均后抹掉原因。

空字符串、明确 NA 和不可解析数值单独计数；负浓度、NaN 或无穷值判为非法，保留源值供追溯。极端正值先标记和核查，不凭“看起来太大”删除污染峰值；任何上限过滤要有来源依据和敏感性结果。

7.3 覆盖表和缺失

为计划日期、站点生成完整小时轴，将实际观测左连接上去。缺源文件、缺类型行、缺站点列和数值空缺分别标记，不能全部写成零或笼统称停站。

覆盖报告至少按月份和站点统计有效小时率、最长连续缺口、来源文件完成率、别名映射和异常比例。近年四天样本只证明那些日期可读，不能替代这份完整范围报告。

7.4 训练期站点面板

只按训练期信息选择站点。默认要求：有稳定身份映射；训练期 PM2.5 有效观测率至少 85%；至少 180 个有有效观测的日期。保留全部合格站点，不按测试期表现选“容易预测”的站点。

这些阈值是本项目设计建议。若真实情况不适合，应在首次正式测试前由三人登记调整；报告入选 / 排除站点数、原因及样本覆盖。若合格站点过少，先核查数据，不以降低阈值掩盖问题。

7.5 对账与独立复核

A 交付原始日数、成功 / 失败日数、宽表类型行数、长表值数、有效 PM2.5 数、缺失和冲突数；按互斥处置原因对账。宽转长前后的每站小时值应逐键一致，不能把多种统计类型累加成更大的样本量。

C 用标准 Python 对一个真实完整月或获准子集独立读取、筛型和展开，与 A 的 Spark 输出逐键核对；不导入 A 的同一清洗函数充当独立检查。差异输出源文件、主键、两侧值和解释，修复后重验。

7.6 必备的小样例

人工 fixture 覆盖：整点边界、跨日、三个预测跨度、缺源小时、空值与零值、类型混淆、重复冲突、站点改名、训练 / 验证边界。文件、页面和 run 均标为 `synthetic_fixture`。真实 UCI 演练则标为历史数据，不能与人工样例混称。

08 时间切分、特征与信息边界

8.1 近期默认切分

以下边界全部为北京时间零点，右端不含。只有在近期全量范围验收后才冻结成正式配置；当前是清晰的执行默认值。

阶段	默认期间	作用
预热	2024-01-01 至 2024-01-08	提供最长 168 小时历史，不计模型成绩
训练	2024-01-08 至 2025-01-01	拟合模型、插补统计和站点面板
验证	2025-01-01 至 2025-07-01	选参数、强基线和展示默认模型
测试	2025-07-01 至 2026-01-01	冻结后最终评价

某阶段样本必须同时满足发布时间在阶段内、目标结束时间不晚于阶段右边界。h=3、6 会分别去掉阶段末尾 2、5 个发布小时，防止训练标签跨入验证、验证标签跨入测试。

2024 为闰年，预热 168 小时、训练发布时间理论 8,616 小时；2025 上半年 4,344 小时，下半年 4,416 小时。h 的理论上限分别再减 h−1，随后按真实站点、缺失和资格规则统计，不能把理论上限当实际样本量。

8.2 固定模型，滚动更新历史

首版模型与预处理器只在训练期拟合；验证集选择配置后锁定。最终测试每个整点 T 向前移动，允许使用按回放假设已经可得的真实过去观测更新 lag，但不把验证或测试标签重新加入训练。

这是每个时点分别预测的历史滚动实验，不是在 2025 年 7 月 1 日一次预测完整半年。2026 年数据可在核心测试锁定后作为附加近期检验，单列版本与结果，不能再据此反复调整原测试结论。

8.3 三个跨度使用直接预测

分别训练 h=1、3、6 的模型，输入均来自发布时间 T 之前，输出为各自目标小时。首版不采用“把第一个预测当真实值再递推”的递归方案；因此三个跨度的差异可直接用各自真值评价。

8.4 基本特征定义

特征组	首版内容	时间约束
PM2.5 历史	lag 1、2、3、6、12、24、48、168	lag k 对应小时开始为 T−k
滚动统计	过去 3、6、12、24 小时有效均值	窗口只含 [T−w,T)，并记录有效个数
缺失与变化	lag 缺失标记、历史有效率、lag1−lag2	从同样过去窗口计算
日历	目标小时、目标星期、月份、周末	预测发布前已知；小时可作 sin/cos 周期编码
站点	训练确定的站点编码	字典冻结；测试新站点标为面板外

小时序列先补完整时间轴再做 lag；不能直接按“上一条非空行”移动，否则跨缺口会把昨天记录当一小时前。时间滞后与填补都应有单独测试。

8.5 输入缺失与目标缺失

目标小时缺观测时不插补标签，不参与误差分数；缺真值量和原因始终报告在候选索引中。所有模型的可计分集合由统一真实标签规则确定，不能由预测成功与否决定。

输入 lag 空缺使用训练期该站有效 PM2.5 中位数，附加原始缺失标记；若站点中位数不可得，使用训练全局中位数。滚动均值用窗口内真实有效值，全部缺失时用同样训练统计填补。所有插补统计冻结，验证和测试不得重新拟合。

派生特征采用固定计算顺序：先记录各 lag 的原始缺失标记，再完成 lag1、lag2 的上述填补，最后计算 `lag1-lag2`。历史有效率固定为过去 24 个整小时有效原始观测数除以 24，不将填补值计为有效观测；滚动窗口有效个数同样只统计原始有效值。特征清单记录公式、窗口、填补值来源与字段顺序。

为避免在严重缺历史时假装正常预测，过去 24 个小时有效原始观测少于 12 个时，所有方法统一进入后备模式；输出持久性后备链和 `prediction_origin=fallback`，仍保留在有真值的固定评价集合内。另报正常模型模式与后备模式的误差及比例，不能只展示较好的一组。

8.6 必须防住的信息泄漏

随机打散时序会让未来影响训练；跨站点滚动计算会混入其他站序列；全期插补、标准化、站点筛选或峰值阈值会提前利用测试信息。所有拟合统计从训练得到，所有时序窗口按数据集和站点分组，并严格截止 T。

禁止使用目标小时真实浓度、目标小时其他实测污染物、未来真实天气、当天最终均值、事后排名或用未来值双向插补。输入里若保留原始数据中的滚动统计，也必须核对它对应的时间窗口与发布时间。

8.7 配套气象的扩展条件

NOAA ISD 等公开来源提供小时级温度、气压、风向风速等候选数据；北京对应站点、年份、质量标记、时区与污染站匹配尚未在本项目验证。[S5]

扩展先使用发布时间前的气象观测，形成“基本特征”与“基本＋历史气象”消融。若要用目标时刻天气，只能使用当时已发布的天气预报，并保存预报发布时间；事后气象观测或再分析不能直接当作当时已知的未来天气。缺乏历史到达日志时说明可得性假设。

09 基线、机器学习与实验预算

9.1 两个必须比较的规则

B1 持久性基线： 所有跨度首先预测为最近已知 PM2.5，即 `y[T-1]`。短期序列可能变化不大，这条规则应作为认真对手，不能只与一个很弱的均值模型比较。

B2 上一日同期： 预测为目标小时前一天的观测，即 `y[T+(h-1)-24]`。例如 h=6 使用 T−19 的小时值，它在 T 前已经结束，不使用未来标签。

统一后备链为：最近小时值；若空则取 T 前最近 3 个已结束小时中的最新有效值；仍不可得则用冻结的训练站点中位数，再到训练全局中位数。B2 的昨日同期缺失时进入该链；低历史覆盖时各方法统一走该链。每条预测保留后备原因。

9.2 RF 与 GBT

RF 通过多棵树组合历史与日历特征，GBT 用逐步提升的树拟合预测误差。首版直接使用 Spark ML 的回归实现，重点是特征、时间边界、公平评价与工程证据，不要求自行重写算法。[S4]

每个跨度各训练一套 RF 和 GBT，使用同一训练行、同一原始特征含义与输入填补方案。站点类别编码的字典只在训练拟合；明确 categorical 特征元数据及 `maxBins` 能覆盖站点类别数，不能把任意站点编号悄悄当有大小顺序的连续量。

9.3 首版参数预算

算法	候选组合	固定约定
RF	numTrees 为 50 或 100； maxDepth 为 5 或 8，共 4 组	seed=42；其他参数记录并固定
GBT	maxIter 为 30 或 60； maxDepth 为 3 或 5，共 4 组	stepSize=0.05，seed=42

三个跨度合计 24 组候选训练，不含基线、微型演练和消融。资源不足时可在正式测试前统一缩小预算，保留调整原因；不要给某一方法反复增加搜索直到胜出。

每个跨度按验证 MAE 选配置；与最低值差不超过 0.000001 μg/m³ 时，依次选较小深度、较少树 / 迭代，再按配置 ID 排序。6 小时为主研究跨度，但 1、3 小时仍完整报告。

9.4 冻结与模型交付

验证完成后冻结各跨度的强基线、RF/GBT 配置和展示默认模型。默认模型按该跨度验证 MAE 在全部候选方法中选出，规则方法同样有资格获选；最终测试不重新选择“最好看的”方法。

先按第 9.3 节为每个模型家族选出一个配置，再比较 B1、B2、RF、GBT 的验证 MAE。与其中最低值差不超过 0.000001 μg/m³ 的方法视为并列，固定按 B1、B2、RF、GBT 的顺序选展示默认项；该顺序只是可复现的并列裁决，不表示预先认定优劣。可选 LSTM 若纳入正式协议，排在 GBT 后，须在测试前冻结。

交付模型目录、预处理统计、特征名称及顺序、类别字典、数据与代码版本、完整配置、种子、训练和推理耗时、验证成绩及运行日志。每次重跑生成新 run_id，不能只覆盖一张成绩表。

9.5 最小消融与解释

使用同一种树模型做“日历＋站点”与“日历＋站点＋历史 PM2.5”比较，其他条件相同，检验历史特征的实际作用；有气象数据后再追加气象消融。消融先用验证选择和分析，最终测试只按冻结协议运行。

可展示训练模型的特征重要性，或在验证集做固定方案的置换分析；注明它描述模型依赖，不是污染因果解释。不得根据测试重要性再反复改特征并仍把同一测试称为未见数据。

9.6 可选 LSTM

深度学习不是首版验收条件。若团队在核心版本后有资源，可以用同一目标、切分、面板和真值比较一个小型 LSTM，输入过去 24 小时，隐藏维度 32 或 64，最多 30 个 epoch，验证集早停。缩放只在训练拟合，记录多随机种子波动与计算成本。

LSTM 是否改善由实验回答。首版不承诺它优于树模型，也不为展示更多技术引入大模型问答或复杂网络。

10 评价协议：怎样证明模型有用

10.1 先冻结协议，再看最终测试

`evaluation_protocol.json` 记录数据、站点、特征与代码版本，默认切分和边界过滤，三个跨度的固定候选 / 计分索引，真值版本、模型预算、强基线、主指标、分组和峰值阈值。B 负责生成，C 独立复核，三人确认后打开最终测试。

后续任何变更生成新协议，保留旧结果。第一次看过的测试范围已不再完全未知，不能反复改模型后把其中最好一次描述为独立最终验证。

10.2 MAE、RMSE 与提升率

同一跨度上有 N 条真实目标，真实浓度为 y，预测为 p：

```
MAE  = sum(abs(p - y)) / N
RMSE = sqrt(sum((p - y)^2) / N)
相对改善 = (MAE_强基线 - MAE_模型) / MAE_强基线
```

MAE 为主指标，MAE 和 RMSE 单位均为 μg/m³。强基线是在对应跨度验证集上 B1、B2 中 MAE 更低的方法，并列按固定规则选 B1。强基线 MAE 为零时相对改善为 null，并附原因；空测试集合直接失败，不输出零误差。

可附 R^2，但当真实值没有变化、分母为零时输出 null；R^2 可能为负。首版不把逐点百分比误差作为主指标，以免低浓度和零值导致误导。

10.3 计分覆盖与完整性

每个跨度报告候选小时数、有真值数、无真值数及原因、应预测数、实到数、重复 / 额外 / 缺失预测数、后备比例和站点数。缺真值样本不计误差，始终列在覆盖报告；有真值且在固定集合内的样本，必须有合法预测。

预测主键重复、NaN / 无穷、错误跨度或应有预测缺失，都使该运行完整性不通过。统一后备可以提供合法数值，但要保留标记；不能只取各模型成功样本的交集来制造公平比较。

10.4 站点、季节与时段分组

逐站点报告 MAE、RMSE、样本量和后备比例；同时给所有行加权总体 MAE 与各站点 MAE 的简单平均，避免完整站点或大样本站点掩盖其他站点。测试期只有半年时，季节表只报告实际覆盖的季节，不宣称四季均验证。

按目标小时开始时刻转换成北京时间后，提取小时、工作日 / 周末、月份或实际覆盖季节，不能按预测发布时间分组。周末固定为周六、周日，不等同含调休的法定工作日；季节固定为春 3—5 月、夏 6—8 月、秋 9—11 月、冬 12—2 月。峰值与非峰值单独报告，列出误差最大的十个站点目标小时。图表不只挑选准确日期，页面允许访问失败案例。

10.5 相对高浓度小时识别

在每个入选站点的训练有效原始值上取 95% 分位数作为该站阈值 q95，测试真实值和预测均按 `>=q95` 判断峰值。阈值固定，不在验证或测试重新估计；训练序列恒定时该站峰值指标标记不适用，并说明原因。

报告 TP、FP、FN、Precision、Recall、F1：Precision=TP/(TP+FP)，Recall=TP/(TP+FN)，F1=2TP/(2TP+FP+FN)。各自分母为零时该项为 null，保留计数。峰值阈值是研究中的相对阈值，不等同法定污染等级或官方预警标准。

首版评价的是目标小时高浓度识别，不把单小时阈值命中自动解释为发现完整污染过程。若扩展成连续事件预警，另行定义事件起止、提前量与事件级漏报。

10.6 稳定性分析

对每个跨度使用相同站点和同一天的配对预测，以目标小时开始时刻所属的北京自然日为重采样单位，bootstrap 2,000 次，报告模型减强基线 MAE 差值的 95% 区间。将有计分样本的日期升序列成长度 D 的清单，每次有放回抽 D 个日期；抽一个日期时纳入该日所有计分站点小时，日期被重复抽到时重复计入。每次分别按抽中全部行计算模型与基线 MAE，再求差，保留跨站相关结构，不先平均每日 MAE。

使用 NumPy `Generator(PCG64(42))` 生成日期下标，保存 2,000×D 的抽样下标表、日期清单和文件哈希。区间采用 percentile 法，对 2,000 个差值取 0.025 与 0.975 分位数，分位数插值固定为 `method=linear`；训练 q95 阈值也使用线性分位数。运行协议记录随机数库版本、种子、抽样次数与分位数算法；C 读取同一抽样表独立重算，避免不同库随机序列造成假差异。有效日期少于 30 天时区间记为不适用，并报告日期数。

该区间是课程实验的稳定性分析，不消除全部跨日时间相关，也不证明因果。计算预算允许时可加连续多日分块敏感性分析。区间跨零时，不把“平均略好”写成稳定显著改善。

10.7 独立重算与手算测试

C 使用独立实现读取逐行预测、固定索引和原始真值，先对主键、版本、时间与行数做全量检查，再重算总体 / 分组 / 峰值指标及第 10.6 节稳定性区间。不调用 B 的同一评价函数作为独立验证。计数、主键、日期清单和 null 原因必须完全相同；非空数值按双精度计算，绝对差不超过 0.000001 才通过，报告最大差值与检查结果。界面显示的四舍五入值不用于复算。

人工例子：真值 `[0,2,4]`，预测 `[1,2,3]`，MAE=2/3，RMSE=sqrt(2/3)。再检查空集合、全常数、零分母、重复键、少一条预测、负数、NaN、错站点和跨边界标签。这些测试验证计算，不能当真实模型成绩。

10.8 什么结果允许写进结论

模型在固定未来测试上优于强基线，且分组、高峰和后备情况能解释时，可以报告指定范围内的实测改善。改善不稳定或只出现在部分站点时，应给限定结论。

模型不胜基线，也应提交完整数据流程、基线服务和失败分析，说明季节变化、污染突变、输入不足或模型限制的证据。预测质量不等于界面质量，两部分分别验收。

11 图形交互与页面规格

11.1 页面一：来源、覆盖与数据概览

顶部显示数据集、日期范围、更新或核验时间、有效站点数和缺失率。用年月筛选、站点列表、站点小时覆盖矩阵和浓度分布展示原始数据状况。用户可点击缺失月份查看原因、源清单和统计。

历史分布与来源说明使用 `retrospective_review` 回顾模式；如果页面被切换到历史回放，则概览卡片、统计与排名也必须遵守回放时间的信息边界。

11.2 页面二：站点趋势与对比

用户点击列表或已核验地图上的站点，查看历史 PM2.5、缺失段和季节时段分布；支持选择多个站点对比，但限制同时绘制数量，保持曲线可辨。默认展示相同单位和相同时间范围。

地图坐标未验证时用站点列表和热力矩阵完成同样选择功能。地图底图与坐标有来源、署名和许可要求；不为了效果猜测站点位置。

11.3 页面三：预测历史回放

用户选择回放整点 T，切换 h=1、3、6 和模型，查看指定站点的发布时点、目标区间、预测浓度、后备状态与历史上下文。拖动滑块相当于切换发布时间，不是把事后曲线换色后称预测。

首版回放发布时间仅开放已冻结正式测试期内的已生成发布点；较早日期使用回顾模式。默认最早发布为北京时间 2025-07-01 00:00，此前的训练与验证信息已结束。各跨度还需满足自己的目标结束边界；不能把最终选型模型回放到训练期或验证期，造成模型选择信息提前可得的假象。

在同一发布时间显示 1、3、6 时，只画三个已计算的目标点；连接线注明仅为视觉连接，不代表其余小时已有预测。查看连续轨迹时，固定跨度 h，按不同发布时间展示对应目标小时的预测序列，横轴明确标为目标时间。

回放中目标小时尚未结束时，真实值保持隐藏；切换到回顾模式后才显示实际曲线、误差和失败案例。顶栏持续显示模式，避免用户把事后评价当实时能力。

11.4 页面四：模型比较与误差案例

通过跨度、站点、月份与模型筛选，展示相同计分集合的 MAE、RMSE、峰值 Recall/F1、样本覆盖和后备比例。默认显示各跨度验证选定模型，保留所有测试方法的成绩。

点击指标进入对应逐行案例和误差分布；点击高误差点展示预测值、真值、发布时间、可用历史及质量标记。指标卡附简短固定说明，不需要对话入口或大模型生成解释。

11.5 视觉与交互验收

浓度图标明 μg/m³、北京时间、数据范围和模型；观测实线、预测虚线，颜色之外再用线型区分。缺失留断点或明确标记，不能连接成零。图表从同一服务结果绘制，悬停数值与导出一致。

时间滑块同时支持键盘与日期输入；筛选为空时给出范围提示，网络或结果不可用时保留可解释错误。站点改名、无坐标、跨度边界没有预测均有明确状态。首版目标为桌面演示，窄屏至少能完成筛选与读取核心指标。

12 服务接口、结果库与信息门控

12.1 结果库

C 将已校验的站点注册表、观测、预测、指标和数据质量元信息导入 SQLite，导入完成生成只读服务库。原子替换服务版本，页面响应都返回 dataset_id、run_id、协议与模式。多人不共用一个 SQLite 文件并发写入。

导入校验主键、数据 / 站点 / schema 版本、数值范围、目标时间公式和模型清单。发现错误即停止，不自动改名、猜时区或补全不一致字段。

12.2 HTTP 接口

路径	主要用途	关键参数或约束
GET /api/v1/datasets	数据范围、来源、质量与版本	返回实际范围和当前状态
GET /api/v1/stations	面板与全部已知站点	区分建模资格和可展示位置
GET /api/v1/observations	观测曲线与覆盖	station、时间、mode、replay_time
GET /api/v1/forecasts	指定发布时点和跨度预测	issue_time、horizon、model_id
GET /api/v1/metrics	固定测试和分组指标	仅 retrospective_review 模式
GET /api/v1/quality	覆盖、缺失和核验统计	回放模式只展示当时允许信息

数据查询必须指定数据集和模式。`historical_replay` 要求 `replay_time`；`retrospective_review` 用于冻结结果回顾。所有端点用同一时间工具和版本判断，不能只在前端隐藏未来。

12.3 回放信息边界

预测只有 `issue_time <= replay_time` 才允许出现；真值只有 `target_end <= replay_time` 且满足可得时间政策才可显示。历史观测、图表、质量统计和排名同样遵守边界；若某统计会泄露未来全期信息，在回放中隐藏或只按可见历史重算。

另校验模型信息时点：运行元信息保存 `train_information_end`、`selection_end` 和由其确定的 `replay_min_issue`。首版所有回放请求均要求 replay_time 不早于正式测试开始，发布时间位于该运行允许区间且不早于 replay_min_issue。否则返回 422 `replay_out_of_range`；不能仅检查曲线数值的时间。实际离线执行的 trained_at 另作审计记录，不与模拟的业务回放时钟混为一谈。

某模型的固定训练数据与元信息可以显示，但训练之外的未来真实浓度不能经汇总接口泄露。最终 metrics 仅用于回顾模式；回放请求该端点返回 422 `mode_not_supported`。

12.4 状态和错误

不存在的站点返回 404；非法时间、模式或跨度返回 422；尚未发布的预测返回 `forecast_not_issued`。面板外站点可正常显示观测，预测状态为 outside_panel，不伪造零预测。

错误体含稳定 code、简短 message 和 request_id。数值为空时同时返回原因枚举；导出 CSV 的空值规则与接口一致。样例页面必须标 `synthetic_fixture`，不能使用现实站点名制造已接入真实数据的错觉。

12.5 人工接口样例

以下仅用于联调字段，不是真实模型成绩。北京时间 10:00 对应 UTC 02:00，h=6 的目标为 UTC 07:00—08:00。

```
{
  "data_origin": "synthetic_fixture",
  "dataset_id": "air_fixture_v1",
  "station_id": "S001",
  "issue_time_utc": "2025-07-01T02:00:00Z",
  "horizon_hours": 6,
  "target_start_utc": "2025-07-01T07:00:00Z",
  "target_end_utc": "2025-07-01T08:00:00Z",
  "prediction": 42.5,
  "unit": "ug/m3",
  "forecast_status": "ok",
  "actual_value": null,
  "actual_status": "not_yet_observed"
}
```

13 三人三 AI 分工与交接

13.1 三个主责

A 数据与环境负责人： 管来源和使用记录、采集 manifest、站点身份、时间与单位、清洗质量、HDFS/Parquet、环境兼容。A 维护公共数据 schema 的版本，含义变化需 B、C 共同确认。

B 模型与实验负责人： 管切分、面板、特征、插补统计、两基线、RF/GBT、回放、评价协议及实验报告。B 不为了提高指标修改 A 的源质量标记或私自换测试范围。

C 应用与独立验收负责人： 管结果导入、只读服务、API、图形界面、A 的独立样本对账、B 的独立指标重算、回放时间门控与答辩演示。C 的验收脚本保持独立逻辑，不只是复用被验收函数。

13.2 文件责任边界

所有者	主修改范围	主要交付
A	data、source 配置、数据测试、schema	manifest、站点表、小时表、质量报告
B	model、实验配置、模型测试	冻结协议、模型、逐行预测、实验结果
C	serving、frontend、OpenAPI、验收	结果库、交互页面、独立核算与演示

三人各用独立 clone 或工作树和分支，各自 AI 在对应目录工作。公共时间工具、字段、版本和 OpenAPI 的变更用同一变更单说明影响，经三方确认后同步；不让三个 AI 在共享工作目录同时改同一文件。

13.3 第一批任务与完成证据

A01 来源与近期数据验收： 取得并登记拟定期间，核验站点、日期、单位、用途和缺失，输出 manifest 与范围决定。完成标准是可读取产物和质量报告，不是只列下载链接。

A02 环境与小时表： G1 小表读写和模型微测通过，再把真实样本转成长表与完整小时轴。交 C 逐键对账通过后扩大正式范围。

B01 手算与协议草案： 用 fixture 确认时间、三个跨度、标签边界、公式和完整性检查；形成配置草案。此任务与 A01 可并行，不生成虚构正式成绩。

B02 面板、特征与基线： 依赖 A 的有效小时表，冻结面板和索引，完成两基线与后备规则；先交一个真实站点的 6 小时结果供 C 联调。

C01 契约与交互骨架： 基于明确 fixture 建结果导入校验、OpenAPI、站点选择、日期和曲线；真实数据接入前持续显示样例标记。

13.4 后续任务与依赖

B03 RF/GBT 验证选型 依赖 B02；**B04 最终测试** 依赖配置冻结和 C 的评价正确性检查。**C02 真实结果库与页面** 可在首个真实链路通过后推进；**C03 全量独立验收** 依赖 B04；**C04 答辩与复现** 依赖共同签收。

A 在模型阶段继续负责源异常修复与性能证据；修复如果改变数据内容，需要新数据版本并重跑受影响实验，不能只修正页面数值。

13.5 交接模板

```
任务编号与状态：
代码提交、修改范围：
输入数据 / schema / station / feature 版本：
输出 run_id、文件、行数、主键与哈希：
实际运行命令与环境：
检查通过、失败与证据位置：
已知限制、未做项：
接收方下一步与依赖：
```

状态统一 pending、in_progress、blocked、ready_for_review、accepted。每个“完成”应有可读取产物、真实命令和检查结果，AI 不用“应该正常”代替运行证据。

14 排程、验收门与风险处置

14.1 建议排程

以下为三人具备基础、可持续协作时的 15 个工作日参考，总人时暂估 80—125，未做实际测时。采集访问故障、完整性修复和课程硬要求会改变工期，最终期限按老师要求另行冻结。

阶段	建议时段	必须交付的证据
范围与小链路	第 1—3 工作日	近期数据范围验收、环境检查、真实单站 6 小时链路
数据与基线	第 4—6 工作日	正式小时表、质量、面板、固定索引和两基线
模型与应用	第 7—10 工作日	RF/GBT 验证、真实查询库与交互页面
最终测试	第 11—13 工作日	冻结测试、独立指标、分组与稳定性分析
收尾与缓冲	第 14—15 工作日	复现、报告、演示和失败情形检查

14.2 七个验收门

门槛	通过条件
G0 范围与数据	课程要求已记录；近期来源、用途、真实期间与站点范围可执行
G1 环境	HDFS/Spark 小表读写、窗口及微型模型成功，版本与资源留档
G2 数据	宽转长与小时质量报告，A/C 独立对账，数据和站点版本冻结
G3 基线	时间和边界手算通过，索引固定，两基线全覆盖，后备可追溯
G4 模型	验证选型与协议冻结，预算和模型产物完整
G5 应用	导入、API、交互、未来真值门控、错误与缺失均验收
G6 交付	最终结果可独立重算，复现说明、三方签收和答辩完成

14.3 数据与资源风险

近期某些日期缺失时，以覆盖状态表达；若不足以支撑默认实验，在看正式测试前共同缩范围和更新协议。若近期来源不可持续，保留已取得的合法版本，启用独立历史演练；需要把历史数据改为正式范围时先由团队确认，不冒充近年。

站点映射或坐标不明时，先保留可核验的站点时序，地图使用列表和矩阵替代；身份不确定的序列不强行拼接。使用条件不明时先限于已确认用途，并在公开原始数据前落实规则。

资源不足时减少候选配置、缓存与并发，以单站和小时间段验证后分层扩大；保持同一评价范围与信息边界。若老师要求 YARN 或 MapReduce，在 G0 加入真实实现任务和验收，已有 WordCount 不能充当项目级实现。

14.4 结果和协作风险

模型不胜基线时保留结果并分析，不换测试范围。高峰漏报严重时，即使总体 MAE 较低也应展示局限。来源延迟假设不成立时，明确历史回放范围，实时能力单独评估。

代码冲突通过独立分支、契约版本和交叉审查解决。优先删扩展功能，保住真实数据、强基线、可靠评价和可解释界面；三人均应能讲清自己的模块和与其他模块的关系。

15 成果包、性能证据与答辩

15.1 软件阶段的最终成果

最终应包括代码和依赖锁定、数据获取与来源说明、manifest 和质量报告、schema 与 OpenAPI、冻结配置、模型与预处理产物、逐行预测与可重算指标、服务与前端、演示脚本、复现 README 和课程报告。真实数据是否随包分享按来源要求决定。

本次指导书包仅含阅读文档和已有核验证据，不含已实现软件、正式近期年度数据、训练好的模型或最终成绩。示例命令和 JSON 为待实现规格与人工说明。

15.2 性能实验

使用同源真实的一个月、半年、一年和实际可得完整范围等子集，保持相同处理逻辑与环境，记录输入字节、行数、站点小时数、分区、耗时、峰值内存、输出量和正确性对账。每规模至少 3 次，区分冷启动和后续运行，报告中位数和范围。

复制原数据可以单独用作负载测试，但不能称新增真实样本，也不能加入预测训练和泛化评价。单机或伪分布式结果不声称已证明多机集群加速；小数据上 Spark 可能有启动开销，应如实展示。

15.3 复现与演示

复现 README 指明输入版本、来源取得方式、环境锁定、按序命令、输出位置、预期主键 / 数量检查及失败处理。C 从干净结果目录重跑小样本，核对数据、预测和指标；不以网页能打开代替实验复现。

演示顺序：来源和覆盖 → 一个真实站点的历史与缺失 → 在整点发布预测并隐藏未来真值 → 回顾模式比较真实值 → 切换基线/RF/GBT 和跨度 → 展示高误差与高浓度漏报 → 独立指标与运行日志。每个结果能追溯 run_id。

15.4 老师可能追问的十个问题

1. 数据来自哪里，最近几年能否取得？展示来源与实际 manifest，区分样本和全量。

2. 为什么使用机器学习？说明监督学习样本、未来标签与可验证的问题，不用算法名称代替动机。

3. h=6 究竟指什么？用第 6.1 节的具体时点例子说明单个目标小时。

4. 是否看见了未来？展示 lag、窗口、阶段末标签过滤、训练统计和回放假设。

5. 为什么需要基线？说明短期持久性规则的竞争力，展示相同样本比较。

6. 指标可靠吗？展示 C 的独立重算、样本覆盖和错误检查。

7. 是否能真正实时预报？首版是历史回放，按日归档的实际延迟与小时可得假设分别解释。

8. 数据是否足够体现大数据？展示真实规模、处理链与实测开销，说明课程范围与扩展空间。

9. 特征重要性是否证明污染成因？说明模型依赖和因果结论的边界。

10. 如果复杂模型没有提升怎么办？展示保留的结果、分组失败与采用强基线的合理性。

16 三位 AI 的启动提示词

16.1 共同使用方式

将本书 Markdown、真实仓库状态和当前任务编号交给对应 AI。第一次回报列出已确认事实、缺少输入、可独立推进项和本次验收目标。以第 6、8、10 章为字段、时间和评价的权威定义，变更只在共同确认后落入新版本。

三位 AI 是开发协作者，产品本身通过图形交互展示。主责外文件先提出修改建议，完成声明附真实命令与产物；文档中的计划和示例不当成已运行结果。

16.2 A：数据工程 AI

```
你负责 A 数据与环境。先读指导书第 1–8、13–15 章。
当前任务编号由我另给；先核对真实文件、已有环境和使用范围。
近期正式范围拟为 2024–2025，现有四天样本不等于全年已取得。
先交来源、用途、日期清单、站点和质量报告，再冻结正式数据版本。
按类型做宽转长，保留缺源、缺值、零值、非法值和冲突的区别。
时间、单位、站点 ID 及版本依第 6 章；原始 hour 含义须写政策并核对。
主修改 data、来源配置、数据测试；公共 schema 含义变更需三方确认。
复用已有虚拟机和脚本，在小表上验证 Spark/HDFS 与极小模型。
交 C 可独立核算的真实子集、小时表、manifest 和实际运行证据。
保留原始数据和旧结果，交接按第 13.5 节，不编造规模或完成状态。
```

16.3 B：模型实验 AI

```
你负责 B 模型与实验。先读指导书第 1、3、6、8–10、13–15 章。
先确认数据、站点、小时定义、质量与版本，按第 8 章冻结切分。
在整点 T 只用 T 前历史，h 目标为[T+h-1,T+h)，h 取 1、3、6。
阶段末去掉目标跨边界样本，训练统计与模型只在训练期拟合。
先实现持久性和昨日同期基线、后备链、固定索引与手算验证。
再按相同样本和预算训练 RF/GBT，在验证选型后锁定正式测试。
主修改 model、实验配置与模型测试，不私改源质量或测试期间。
交付模型、预处理、特征顺序、逐行预测、覆盖和全部实验记录。
6 小时为主指标，分跨度、站点、时段与峰值评价，交 C 独立重算。
差分先填补再计算；分组按目标北京时间；交付固定 bootstrap 抽样表。
模型不胜基线保留结果；每次交接按第 13.5 节附命令和限制。
```

16.4 C：应用验收 AI

```
你负责 C 应用与独立验收。先读指导书第 1、3、6、10–16 章。
主修改 serving、frontend、OpenAPI 和独立验收脚本。
用户通过点击、日期筛选、时间滑块和图表获取信息，产品无聊天入口。
先用 synthetic_fixture 联调，真实结果接入后严格校验主键与版本。
回放所有端点统一隐藏未来真值，发布时间、目标结束和可得政策均检查。
预测回放仅正式测试期，检查模型选型时点与 replay_min_issue。
区分预测/观测、零值/缺失、单时点三跨度与固定跨度连续曲线。
坐标未核验时用站点列表和矩阵，不猜位置；图表保留单位和来源。
独立读取 A 的样本逐键对账，独立按 B 逐行预测与固定索引重算指标。
按目标北京时间分组，读取同一抽样表重算稳定性区间，容差依第 10.7 节。
检查重复、额外、缺预测、空指标、后备比例和错误模式。
交付可复现界面、验收证据与失败案例，交接按第 13.5 节。
```

附录 A　配置、表格和检查模板

A.1 拟实现配置片段

下列为设计默认，不是已经通过数据验收的配置。`approval_status` 在取得并检查近期范围后才改为 approved，并附证据版本；仅修改字符串不能代表真正通过。

```
dataset_id: bj_recent_2024_2025_v1
source_family: quotsoft_beijing_all
approval_status: pending_full_range_check
target: pm25_observed
unit: ug/m3
timezone: Asia/Shanghai
availability_policy: hour_end_assumed
horizons_hours: [1, 3, 6]
primary_horizon: 6
warmup_start_local: 2024-01-01
train_start_local: 2024-01-08
validation_start_local: 2025-01-01
test_start_local: 2025-07-01
end_exclusive_local: 2026-01-01
random_seed: 42
```

A.2 数据范围冻结单

填写数据集、来源与用途、实际首末时间、原始文件清单与哈希、站点映射和版本、有效率与缺口、时间政策、拟用范围和排除原因、A/B/C 复核人及日期。若修改默认期间，附全部新边界与影响，先更新协议再训练。

A.3 实验报告表

每条运行填写 run_id、数据/特征/协议/代码版本、跨度、算法与参数、训练耗时、推理耗时、候选和计分量、缺真值量、后备比例、验证 MAE、测试 MAE/RMSE、强基线相对改善、分组与峰值结果、稳定性区间和限制。未运行项写“未运行”，不填零或复制论文成绩。

A.4 验收检查单

- 来源和近期完整范围有证据；样本、历史数据、人工数据清楚区分。
- PM2.5 小时值与滚动值、AQI、单位没有混淆；站点和时间映射一致。
- lag 按真实小时轴计算，所有输入严格截止发布时点。
- 三个跨度的目标和阶段边界正确，预处理只在训练拟合。
- 基线与模型使用同一计分集合，缺真值与缺预测分开处理。
- 所有成功预测为有限非负浮点数；主键和版本无冲突。
- MAE/RMSE、峰值、分组和稳定性区间由 C 独立重算，空值有明确原因。
- 图形交互能访问真实结果和失败案例，回放无未来真值泄露。
- 原始数据、模型和指标可追溯，复现入口与实际命令一致。
- 结论只陈述实测范围，部署层次、时间假设和扩展状态清楚。

附录 B　现有证据与来源

B.1 随包证据

随包 `核验依据/近期样本核验.json` 为此前四天样本的机器记录，`核验依据/UCI 历史数据全量核验.json` 为此前完整 UCI 数据的数量与质量记录。两者的核验日期是 2026 年 10 月 15 日，本文编制日期为 10 月 16 日；不能把旧核验日期改成今天以制造重新下载的印象。

UCI 记录还含早期可行性基线计算。那组实验只验证历史数据和简单计算链路，不是本指导书新定义近期测试的结果；其数字不进入正式模型比较表。

已有课程环境记录只作为环境复用依据。当前未重新启动虚拟机，未声明新项目 Spark、模型或实时数据源已经验证。

B.2 一手来源

S1 空气质量历史归档发布页：日文件、年度包、类型、单位、缺失和站点变化说明。近期主来源为第三方归档，使用范围另行记录。

S2 UCI Beijing Multi-Site Air Quality：2013—2017 年 12 站历史数据及 CC BY 4.0 许可；DOI 10.24432/C5RK5G。

S3 Spark 4.0.1 官方概览：候选运行环境与 Hadoop 客户端访问方式，不替代本机兼容测试。

S4 Spark 4.0.1 回归文档：RF/GBT 官方实现和参数。

S5 NOAA NCEI Global Hourly/ISD：候选历史气象来源；北京站点匹配与可得时间未在本项目验证。

S6 scikit-learn 时间序列切分文档：按时间评估与避免未来训练过去测试的参考；本项目使用显式日历边界，不随机拆行。

B.3 版本说明

版本 1.0 建立北京 PM2.5 短期预测的新方案，明确近期数据与历史备选、三个预测跨度、直接建模、固定模型滚动回放、基线和树模型、公平评价、图形交互及三人三 AI 协作。后续内容更新先修改 Markdown 主版本，再同步 Word/PDF 与分享包；旧版共享单车文档不作为本项目实施依据。